

Ερωτήσεις:

[1] Διαφορές μεταξύ GFS και HDFS;

GFS: Closed Source

Chunk Size: 64MB

MasterNode - ChunkServer

Multiple Write - Multiple Read

HDFS: Open Source

Block Size: 128MB

NameNode - DataNode

Write Once - Read Many

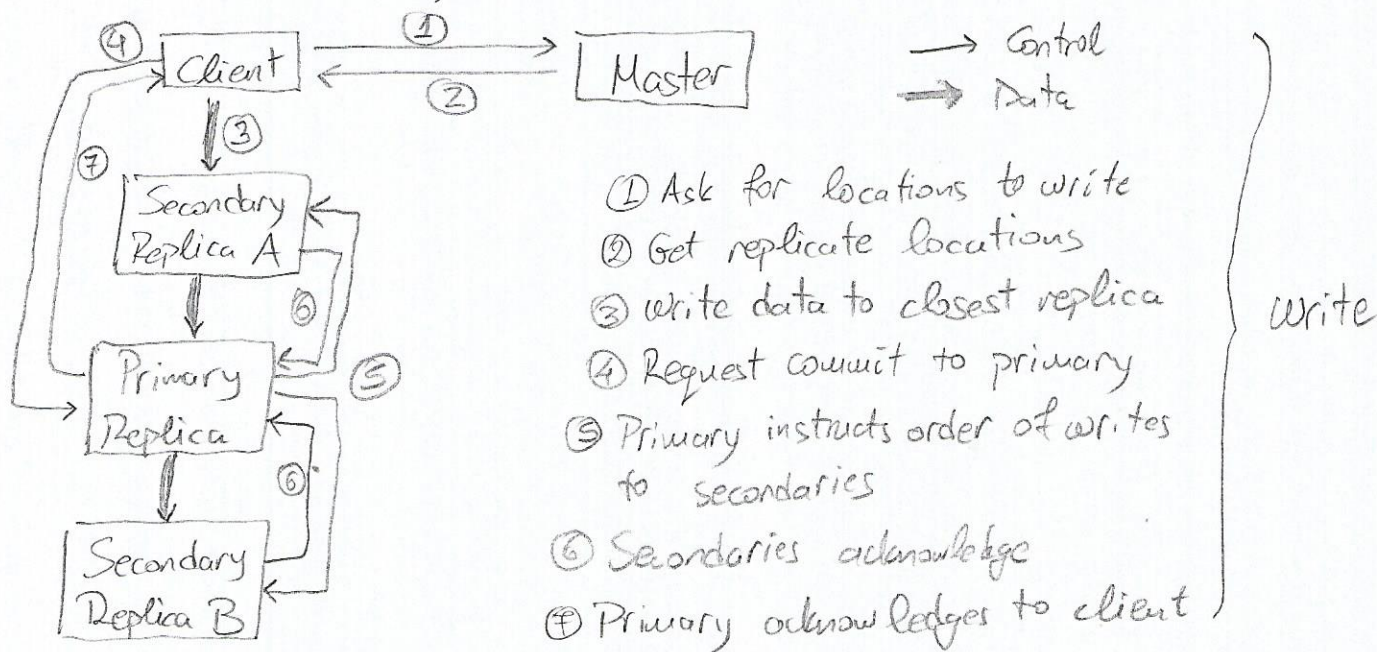
[2] Πώς εξασφαλίζει το HDFS Fault Tolerance;

Κρατά ένα αντίγραφο στον τοπικό κόμβο, ένα σε άλλο κόμβο του rack, ένα σε απομακρυσμένο rack και επιπλέον αντίγραφα σε άλλους κόμβους.

Πέραν αυτού, από τον ηγέτη του NameNode, κρατάται αρχείο των ενοτήτων όχι μόνο στον κόμβο του, αλλά και αλλού, σε περίπτωση που χρειαστεί να αντικατασταθεί.

Αντιστοιχεί για υψηλή διαθεσιμότητα

[3] Πώς λειτουργεί το GFS;



Mutation: σε ένα αντίγραφο αποδίδεται lease, οπότε γίνεται το primary και διαχειρίζεται το mutation στα υπόλοιπα.

[4] Μια σύνοψη του BigTable;

Tablet servers έχουν tablets → σύνδεση SSTables: αποθηκεύονται από blocks
Τα tablets έχουν start-end (αλφαριθμητικά). Ο master αναδίδει tablets σε tablet servers. Το μοίρασμα γίνεται μέσω GFS. Οι ενημερώσεις γράφονται σε μνήμη
620 memtable (αν μεταβώσει το κύριο SSTable και φτιάχνουμε new). Το

[5] Πώς μπορούμε να κάνουμε βελτιώσεις στο BigTable;

- Locality groups (ομαδοποιούν column families)
- Caching (Scan cache: key-value pairs / Block cache: SSTable)
- Compression (τα δεδομένα ^{που} είναι κατά μοίρες μεταξύ τους)
- Commit log (σε ειδικό Tablet server)
- Bloom Filters: χρησιμοποιούνται για να δώσει εάν κάποιο SSTable περιέχει δεδομένα από συγκεκριμένο row, χωρίς να ανοικτούμε το row (λίγος παραπάνω αποθηκευτικός χρόνος, αλλά μπορούμε να αποθηκεύουμε μεγάλο αριθμό SSTables γλιτώνοντας χρόνο). Μπορεί να έχουμε False Positive, αλλά ποτέ False Negative.

[6] Ποια είναι τα βήματα του MapReduce;

- (i) Πρώτα split τα input files σε M κελιάκια (16MB-64MB) και start up πολλαπλές copies στο cluster.
- (ii) Ένα copy για master, τα υπόλοιπα για workers. Ο master αναδίδει M map tasks και R reduce tasks.
- (iii) Κάθε map worker parsάει key-value pairs στον map συνάρτηση και τα αποτελέσματα (intermediate results) γίνονται buffer στη μνήμη.
- (iv) Περιοδικά, τα buffered pairs γράφονται στον τοπικό δίσκο σε R περιοχές, ανάλογα με το πού τα hashάει η partition function. Οι τοποθεσίες αυτές ηγούνται στο master, γιατί αυτός είναι υπεύθυνος να ενημερώσει τους reducers.
- (v) Όταν αδοποιηθεί κάθε reducer, διαβάσει και κατόπιν sortάει όλα τα intermediate data βάσει των intermediate keys.
- (vi) Κάθε reducer περνά ένα-ένα τα keys και για κάθε key εφαρμόζει τη reduce function. Τα αποτελέσματα γίνονται append σε ένα output file.
- (vii) Όταν όλα ολοκληρωθούν, ο master κάνει wake up το user program.

[7] MapReduce Data Locality;

Το χαρακτηριστικό αυτό επιταχύνει τη διαδικασία, καθώς αποφεύγεται η σύμφορηση του δικτύου μέσω μεταφοράς υψηλού όγκου δεδομένων. Έτσι,

[8] Τι είναι η partition function;

Είναι η συνάρτηση που ετερείται περιοδικά αφού ολοκληρωθεί η διαδικασία map για να hashάει τα intermediate keys των intermediate αποτελεσμάτων σε R τμήματα.

[9] Τι είναι οι combiners;

Είναι βελτιστοποιητές που μπορούν να εφαρμοστούν αμέσως μετά το map, προκειμένου να κάνουν κάποια aggregation by intermediate key (δηλαδή το reduce function, γ' αυτό συχνά καλείται και mini-reduce) πριν το shuffling.

[10] Τι είναι τα MapReduce shuffle & sort;

Shuffle: Διανομή των intermediate results στις τοπολογίες των reducers (ίδια keys στον ίδιο reducer)

Sort: Το sorting που πραγματοποιεί κάθε reducer πριν την εφαρμογή της reduce, αφού μπορεί να έχει λάβει πολλά keys.

[11] MapReduce: Small ή large dataset;

Το MapReduce ενδείκνυται για batch processing, επομένως το potential του αξιοποιείται σε πολύ μεγάλα datasets. Σε μικρότερα, οι διαδικασίες συγχρονισμού ενδέχεται να εξισορροπήσουν τα προτερήματα της παραλληλοποίησης. Επίσης, εάν το dataset είναι τόσο μικρό που να χωράει στη μνήμη, η εξοικονόμηση χρόνου είναι λιγότερο μεγάλου, αφού σε χρειάζεται τα writes on disk που γίνονται μετά τις maps.

[12] Τι συμβαίνει όταν ένας mapper αποτυγχάνει καθώς στέλνεται τα δεδομένα του σ' έναν reducer;

Εάν δεν υπάρχουν αντίγραφα επανεκτελείται, αλλιώς speculative execution (αυτό βέβαια αφορά κυρίως γενικά να μην περιμένουν όλοι τον πιο αργό worker, αφού πολλοί κάνουν το ίδιο).

[13] Πόλλοι mappers / reducers;


Σε μικρά datasets μειώνεται η απόδοση. Total size

[14] Lazy Transformations;


Αντι κάθε intermediate μετασχηματισμός να εφαρμόζεται απευθείας στα δεδομένα, τα αποτελέσματα να συλλέγονται και η διαδικασία να επαναλαμβάνεται εκ νέου, η πληροφορία του μετ/μω οδηγεί στη δημιουργία ενός νέου RDD, το οποίο φέρει πληροφορία για το lineage του. Οι μετ/μοι πραγματοποιούνται όπως μόνο όταν δοθεί κάποια οδηγία τύπου execution (π.χ. collect), δίνοντας έτσι ως τότε τη δυνατότητα βελτιστοποιήσεως ως προς τους μετασχηματισμούς.

[15] Narrow - Wide dependencies;

Narrow: κάθε τμήμα ενός parent RDD αντιστοιχεί σε ένα μόνο τμήμα (το node) του child RDD. (εύκολο, θέλει λίγους workers)



Wide: ένα τμήμα ενός parent RDD μπορεί να αντιστοιχεί σε περισσότερα από 1 τμήματα του child RDD (απλό, θέλει shuffle & sort)



[16] Sort or Hash shuffle;

Hash: κάθε mapper δημιουργεί ένα αρχείο για κάθε reducer, οπότε τελικά έχουμε M*R αρχεία. Είναι γρήγορο και δε χάνεται χρόνος I/O, όπως δε συμβαίνει για πολύ μεγάλο αριθμό τμημάτων.

Sort: εφόσον 1 μόνο indexed αρχείο με δεδομένα ταξινομημένα ανά reducer id. Προφανώς είναι πιο απλό από το hashing, αλλά αν δεν έχουμε μικρό αριθμό τμημάτων ή SSD, συμβαίνει.

Default: Sort shuffle, εκτός εάν έχουμε λίγους reducers

[17] Reduce side join;

Γνωστό και ως shuffle join. Mappers αναλαμβάνουν κάθε dataset και κάνουν emit ως intermediate results tuples με key το κλειδί συνένωσης και value τα υπόλοιπα στοιχεία. Το πλαίσιο συγκεντρώνει τα tuples, αναδίδει σε κάθε reducer tuples με κοινό κλειδί συνένωσης

... δεδομένου πως δεν υπάρχει εφασφάλιση ως προς τι θα είναι με την οποία γίνεται το join (πρώτα R και μετά S ή αντίστροφα;). Πιθανές λύσεις σε αυτό είναι [1] να κρατιέται στο μνήμη αυτό που θέλουμε να έχει πρώτο (συμφόρση - η μνήμη μπορεί να κλυθεί να κρατήσει πολλά τέτοια) ή [2] να δημιουργούνται πιο εύκολα intermediate keys, αραιώνοντας τα values.

[18] Map side join;

Γνωστό και ως sort-merge join. Προϋπόθεση είναι τα δεδομένα να είναι ταξινομημένα ως προς το κλειδί συνένωσης και το partitioning τους να έχει γίνει με τον ίδιο τρόπο σε ίσα μέρη (συμ-διαχωρισμός).

⇒ Είναι ρεαλιστικό να περιμένουμε κάτι τέτοιο;

Σε πολλές περιπτώσεις ναι, διότι το join μπορεί να κλυθεί να γίνει στο πλαίσιο ενός καλύτερου workflow, οπότε να είναι εκπληρωθεί οι συνθήκες λόγω προηγούμενων διεργασιών.

[19] Hash join;

Γνωστό και ως broadcast join. Προϋπόθεση είναι το ένα dataset να είναι σημαντικά μικρότερο από το άλλο, ώστε να φορτωθεί στο μνήμη σε ένα hashmap με κλειδί το κλειδί συνένωσης. Το άλλο dataset αναγνώσκεται και γίνεται probe για το κλειδί συνένωσης. (Το μικρό διαμοιράζεται σε όλους τους mappers, το μεγάλο στέλνει, κάθε mapper κάνει probe τον κλειδί συνένωσης στο μνήμη)

Σημείωση: Στα [18], [19] δεν αναφέρονται εν γένει reducers.

[20] Τι join συμφέρει;

Σε ταχύτητα ισχύει hash > map-side > reduce-side.

Αλλά πάλι ανάποδα ως προς το πόσο general purpose είναι.

[21] Τι συμβάλλει στο κόστος ενός SQL ερωτήματος;

Η/ο μεταφορές μεταξύ δίσκου και μνήμης, φόρτος στην επικοινωνία

[22] Query Optimization;

(Thanks grammaria) Δεδομένου ενός λογικού πλάνου των επιθυμητών υλοποιήσεων, προσπαθούμε να πραγματοποιήσουμε βελτιστοποιήσεις ως εξής: μεταφέρουμε selection και projection (filters) operations όσο πιο πρίω γίνεται στο pipeline, ώστε τα joins να μείνουν «για το τέλος» και να πραγματοποιηθούν σε όσο το δυνατό μικρότερο τμήμα των datasets. Πρόδετα, επιλέγουμε το είδος του join που ενδείκνυται δεδομένων των συνθηκών.

Σχετικό ερώτημα περί βελτιστοποίησης

[23] Columnar vs Row-oriented databases;

Αφορούν σχεδιαστές βάσεων δεδομένων. Οι row-oriented είναι εσωτερικά σχεδιασμένες για να είναι βελτιστοποιημένες στη διαχείριση γραμμών. Ενδείκνυνται για workloads τύπου OLTP και γενικά όπου χρειάζεται πληροφορία (read/write) για πολλές ή και όλες τις στήλες. Αν μόνον μερικές από τις στήλες μας αγγίζουν, τότε χρησιμοποιούμε columnar, οι οποίες είναι εσωτερικά σχεδιασμένες για να είναι βελτιστοποιημένες στη διαχείριση στύλων. Παραδείγματα file formats που έχουν columnar indexing είναι τα ORC of Hadoop και το Parquet.