

## Άσκηση 1.1

1. Έχουμε ότι  $v[n] = x[n] * h_1[n]$  και  $y[n] = v[n] * h_2[n]$ . Από τον ορισμό

της συνέλιξης,  $v[n] = \sum_{k=-\infty}^{\infty} x[k] h_1[n-k]$ . Επομένως,  $y[n] = \left( \sum_{k=-\infty}^{\infty} x[k] h_1[n-k] \right) *$

$$* h_2[n] = \sum_{\ell=-\infty}^{\infty} \left( \sum_{k=-\infty}^{\infty} x[k] h_1[\ell-k] \right) h_2[n-\ell] = \sum_{k=-\infty}^{\infty} x[k] \sum_{\ell=-\infty}^{\infty} h_1[\ell-k] h_2[n-\ell]$$

Θέτουμε  $m = \ell - k$  και λαμβάνουμε ότι  $y[n] = \sum_{k=-\infty}^{\infty} x[k] \sum_{m=-\infty}^{\infty} h_1[m] h_2[n-(k+m)]$

$$\Rightarrow y[n] = \sum_{k=-\infty}^{\infty} x[k] \sum_{m=-\infty}^{\infty} h_1[m] h_2[(n-k)-m] = \sum_{k=-\infty}^{\infty} x[k] (h_1[n-k] * h_2[n-k]) =$$

$$= \sum_{k=-\infty}^{\infty} x[k] (h_1 * h_2)[n-k] = x[n] * (h_1 * h_2)[n] = x[n] * h[n] \Rightarrow$$

$$\Rightarrow y[n] = x[n] * h[n] \text{ όπου } h[n] = h_1[n] * h_2[n]$$

2. Ισχύει ότι  $h_1[n] * h_2[n] = \sum_{k=-\infty}^{\infty} h_1[k] h_2[n-k]$ . Θέτουμε  $\ell = n - k$  και

$$\text{έχουμε } h_1[n] * h_2[n] = \sum_{\ell=-\infty}^{\infty} h_1[n-\ell] h_2[\ell] = \sum_{\ell=-\infty}^{\infty} h_2[\ell] h_1[n-\ell] = h_2[n] * h_1[n]$$

$$\Rightarrow h_1[n] * h_2[n] = h_2[n] * h_1[n]$$

3. Έχουμε ότι  $v[n] = x[n] * h_1[n] \xrightarrow{\mathcal{Z}} V(z) = X(z) H_1(z)$  όπου  $H_1(z) = \sum_{r=0}^M b_r z^{-r}$

Αντικαθιστώντας,  $V(z) = X(z) \sum_{r=0}^M b_r z^{-r} = \sum_{r=0}^M b_r z^{-r} X(z) \Rightarrow V(z) = \sum_{r=0}^M b_r z^{-r} X(z) \xrightarrow{\mathcal{Z}^{-1}}$

$v[n] = \sum_{r=0}^M b_r x[n-r]$  από την ιδιότητα  $x[n-m] \xrightarrow{\mathcal{Z}} z^{-m} X(z)$ . Ομοίως

έχουμε ότι  $y[n] = v[n] * h_2[n] \xrightarrow{\mathcal{Z}} Y(z) = V(z) H_2(z)$  όπου  $H_2(z) = \frac{1}{1 - \sum_{k=1}^N a_k z^{-k}}$

$Y(z) = V(z) \frac{1}{1 - \sum_{k=1}^N a_k z^{-k}} \Rightarrow Y(z) \left[ 1 - \sum_{k=1}^N a_k z^{-k} \right] = V(z) \Rightarrow Y(z) - Y(z) \sum_{k=1}^N a_k z^{-k} =$

$= Y(z) - \sum_{k=1}^N a_k z^{-k} Y(z) = V(z) \xrightarrow{\mathcal{Z}^{-1}} y[n] - \sum_{k=1}^N a_k y[n-k] = v[n] \Rightarrow$

$y[n] - \sum_{k=1}^N a_k y[n-k] = \sum_{r=0}^M b_r x[n-r]$

4. Σε αυτή την περίπτωση, έχουμε ότι  $\tilde{v}[n] = x[n] * h_2[n]$

$x[n] \rightarrow [h_2[n]] \rightarrow \tilde{v}[n] \rightarrow [h_1[n]] \rightarrow y[n]$  Επομένως  $\tilde{V}(z) = X(z) H_2(z) =$

$= X(z) \frac{1}{1 - \sum_{k=1}^N a_k z^{-k}} \Rightarrow \tilde{V}(z) \left[ 1 - \sum_{k=1}^N a_k z^{-k} \right] = X(z) \Rightarrow \tilde{V}(z) - \sum_{k=1}^N a_k z^{-k} \tilde{V}(z) =$

$= X(z) \xrightarrow{\mathcal{Z}^{-1}} \tilde{v}[n] - \sum_{k=1}^N a_k \tilde{v}[n-k] = x[n]$


Επίσης,  $y[n] = \tilde{v}[n] * h_1[n] \xrightarrow{\mathcal{Z}} Y(z) = \tilde{V}(z) H_1(z) = \tilde{V}(z) \sum_{r=0}^M b_r z^{-r}$

Επομένως,  $Y(z) = \sum_{r=0}^M b_r z^{-r} \tilde{V}(z) \xrightarrow{z^{-1}} y[n] = \sum_{r=0}^M b_r \tilde{v}[n-r]$ . Τελικά,


$$\tilde{v}[n] - \sum_{k=1}^N a_k \tilde{v}[n-k] = x[n] \quad \text{και} \quad y[n] = \sum_{r=0}^M b_r \tilde{v}[n-r]$$

Οι δύο μορφές των εξισώσεων διαφορών είναι ισοδύναμες.


### Άσκηση 1.3




1. Για να βρούμε την κανονική έκφραση που αντιστοιχεί στην μηχανή, θα εφαρμόσουμε τον αλγόριθμο απαλοιφής καταστάσεων. Η αρχική κατάσταση δεν έχει εισερχόμενες ακμές, επομένως δεν χρειάζεται να κάνουμε κάτι. Η τελική κατάσταση έχει εξερχόμενες ακμές, επομένως θεωρούμε νέα τελική κατάσταση ως εξής:




Αρχικά, απαλοΐφουμε την κατάσταση 2:



Έπειτα, την κατάσταση 3:




Μετά, την κατάσταση 4:



Η ζητούμενη κανονική έκφραση είναι η  $a(ba | bca | bda)^*(bc | bd)$

2. Αναζητούμε την γραμματοσειρά ελαχίστου συνολικού κόστους εφόσον χρησιμοποιούμε τροπικό ημιδακτύλιο. Εύκολα βλέπουμε ότι αρκεί να εξετάσουμε τις γραμματοσειρές  $abc$ ,  $abd$  καθώς οποιαδήποτε άλλη θα είναι της μορφής  $a(ba|bca|bda)+(bc|bd)$  και θα έχει υποχρεωτικά μεγαλύτερο κόστος. Το κόστος της  $abc$  είναι  $2+1.5+2.5=6$  και το κόστος της  $abd$  είναι  $2+1+5+3=11$  καθώς η κατάσταση 3 έχει κόστος 5. Συνεπώς η πιο πιθανή γραμματοσειρά είναι η  $abc$ .

3. Η μοναδική ακολουθία καταστάσεων που αντιστοιχεί στην γραμματοσειρά




με κόστος  $2+1.5+2.5+1+1+1+1+3=13$

4. Η μηχανή που δίνεται στην εκφώνηση είναι μη ντετερμινιστική, καθώς από την κατάσταση 1 με είσοδο  $b$  μεταβαίνουμε είτε στην κατάσταση 2 είτε στην κατάσταση 3. Θα χρησιμοποιήσουμε τον αλγόριθμο μετατροπής από μη ντετερμινιστική σε ντετερμινιστική μηχανή.

	ΕΙΣΟΔΟΣ			
	a	b	c	d
{0}	{1}	-	-	-
{1}	-	{2,3}	-	-
{2,3}	{1}	-	{4}	{4}
{4}	{1}	-	-	-

Με βάση τον παραπάνω πίνακα, η ντετερμινιστική μηχανή που προκύπτει είναι


η εξής:



5. Παρατηρούμε ότι μπορούμε να μεταφέρουμε 0.5 μονάδες κόστους από την


ακμή  $1 \rightarrow 2$  στην  $2 \rightarrow 4$  χωρίς να αλλάξει το κόστος οποιαδήποτε γραμματοσειράς

που γίνεται αποδεκτή, λαμβάνοντας




Συγχωνεύοντας τις καταστάσεις 2,3 όπως στο προηγούμενο ερώτημα λαμβάνουμε

την ισοδύναμη ντετερμινιστική μηχανή με κόστος:



## Άσκηση 1.4

α. Ο ζητούμενος μετατροπέας είναι ο εξής:



$X:Y/1$  όπου  $(X,Y) \in \Sigma \times \Sigma$  και  $X \neq Y$

β. Α' ΤΡΟΠΟΣ με χρήση δυναμικού προγραμματισμού. Εκφράζουμε το κόστος

αντιστοίχισης από την γραμματοσειρά  $S = \text{"EDBAEDC"}$  στην  $T = \text{"CDFABEA"}$  μέσω της

εξής αναδρομικής σχέσης: 
$$D(1..i, 1..j) = \min \begin{cases} D(1..i, 1..j-1) + 1 & \text{(εισαγωγή)} \\ D(1..i-1, 1..j) + 1 & \text{(διαγραφή)} \\ D(1..i-1, 1..j-1) + d(S(i), T(j)) & \text{(αντικατάσταση)} \end{cases}$$

όπου  $D(1..i, 1..j)$  δηλώνει το ελάχιστο κόστος αντιστοίχισης από την  $S(1..i)$  στην

$T(1..j)$ , και προκύπτει είτε αντιστοιχίζοντας την  $S(1..i)$  στην  $T(1..j-1)$  και εισάγοντας

τον χαρακτήρα  $T(j)$ , είτε αντιστοιχίζοντας την  $S(1..i-1)$  στην  $T(1..j)$  και διαγράφοντας

τον χαρακτήρα  $S(i)$ , είτε αντιστοιχίζοντας την  $S(1..i-1)$  στην  $T(1..j-1)$  και αντικαθιστώ-

ντας τον  $S(i)$  με  $T(j)$  αν  $S(i) \neq T(j)$ .

SOURCE	C	7	6	6	6	5	5	5	5
	D	6	6	5	5	4	4	4	4
	E	5	5	4	4	3	3	3	4
	A	4	4	3	3	2	3	4	4
	B	3	3	2	2	3	3	4	5
	D	2	2	1	2	3	4	5	6
	E	1	1	2	3	4	5	5	6
	#	0	1	2	3	4	5	6	7
	#	C	D	F	A	B	E	A	
	TARGET								

Η βέλτιστη αντιστοίχιση έχει κόστος  $D(1..7, 1..7) = 5$  και προκύπτει μέσω 5

αντικαταστάσεων και 2 no edits (7 βήματα):

E	D	B	A	E	D	C
↓	↓	↓	↓	↓	↓	↓
C	D	F	A	B	E	A

3. Η δεύτερη καλύτερη αντιστοίχιση κόστους 5 προκύπτει από διαφορετικό μονοπάτι (διακεκομμένα βέλη) και χρειάζεται 8 βήματα: 3 αντικαταστάσεις, 2 no edits,

1 εισαγωγή και 1 διαγραφή:

E	D	B	A	ε	E	D	C
↓	↓	↓	↓	↓	↓	↓	↓
C	D	F	A	B	E	A	ε

Β' ΤΡΟΠΟΣ Με χρήση του Levenshtein transducer και του λογισμικού Openfst,

βρίσκουμε τα δυο συντομότερα μονοπάτια στην μηχανή  $T \circ L \circ S$  όπου  $S$

ο αποδοχέας της  $EDBAEDC$  και  $T$  ο αποδοχέας της  $CDFABEA$ .



## Άσκηση 2.1

1. Έχουμε ότι  $E_x = \sum_{n=0}^{N-1+p} (x[n] - \hat{x}[n])^2$  όπου  $\hat{x}[n] = \sum_{k=1}^P a_{xk} x[n-k]$

Για  $a_{x0} = -1$ ,  $\hat{x}[n] = -\sum_{k=0}^P a_{xk} x[n-k] + x[n]$ . Επομένως,

$$\begin{aligned} E_x &= \sum_{n=0}^{N-1+p} \left( x[n] - \sum_{k=0}^P a_{xk} x[n-k] - x[n] \right)^2 = \sum_{n=0}^{N-1+p} \left( \sum_{k=0}^P a_{xk} x[n-k] \right) \left( \sum_{k'=0}^P a_{xk'} x[n-k'] \right) \\ &= \sum_{k=0}^P a_{xk} \sum_{k'=0}^P a_{xk'} \sum_{n=0}^{N-1+p} x[n-k] x[n-k'] \quad (1) \end{aligned}$$

Επίσης,  $\sum_{n=0}^{N-1+p} x[n-k] x[n-k'] \stackrel{n'=n-k}{=} \sum_{n'=-k}^{N-1-k+p} x[n'] x[n'+k-k']$

Όμως,  $x[n'] = 0$  για  $n' < 0$  και  $x[n'+k-k'] = 0$  για  $n'+k-k' > N$

Επομένως  $n'_{\min} = 0$  και  $n'_{\max} + k - k' = N - 1 \Rightarrow n'_{\max} = N - 1 - k + k' \leq N - 1 - k + p$

καθώς  $k' \leq p$ . Συνεπώς,  $\sum_{n'=-k}^{N-1-k+p} x[n'] x[n'+k-k'] = \sum_{n'=0}^{N-1-k+k'} x[n'] x[n'+(k-k')] =$

$= \sum_{n'=0}^{N-1-(k-k')} x[n'] x[n'+(k-k')] = R_x(k-k') = R_x(k'-k)$  λόγω συμμετρίας, καθώς μπορούμε

να εναλλάξουμε τα  $k$  και  $k'$ . Επομένως,  $E_x = \sum_{k=0}^P a_{xk} \sum_{k'=0}^P a_{xk'} R_x(k-k') =$

$$= \sum_{k=0}^P a_{xk} \vec{a}_x \begin{bmatrix} R_x(k) \\ R_x(k-1) \\ \vdots \\ R_x(k-p) \end{bmatrix} = \vec{a}_x \sum_{k=0}^P a_{xk} \begin{bmatrix} R_x(k) \\ R_x(k-1) \\ \vdots \\ R_x(k-p) \end{bmatrix} = \vec{a}_x \begin{bmatrix} R_x(0) & R_x(1) & \dots & R_x(p) \\ R_x(1) & R_x(0) & \dots & R_x(p-1) \\ \vdots & \vdots & \ddots & \vdots \\ R_x(p) & R_x(p-1) & \dots & R_x(0) \end{bmatrix} \begin{bmatrix} a_{x0} \\ a_{x1} \\ \vdots \\ a_{xp} \end{bmatrix} =$$

$= \vec{a}_x R_x \vec{a}_x^T \Rightarrow E_x = \vec{a}_x R_x \vec{a}_x^T$  όπως θέλαμε να δείξουμε.

2. Εργαζόμαστε με τον ίδιο τρόπο, χρησιμοποιώντας τους συντελεστές  $\vec{a}_y$  και προκύπτει

$$\text{ότι } E_{xy} = \vec{a}_y R_x \vec{a}_y^T$$

3. Εξ ορισμού η ενέργεια του σφάλματος είναι ελάχιστη για τους συντελεστές γραμμικής πρόβλεψης  $\vec{a}_x$  και οποιοδήποτε άλλοι συντελεστές θα αντιστοιχούν σε ίση

ή μεγαλύτερη ενέργεια σφάλματος, δηλαδή  $E_{xy} \geq E_x \Rightarrow \frac{E_{xy}}{E_x} \geq 1$

## Άσκηση 2.2

Για  $t=1$ , έχουμε ότι  $\delta_1(i) = P(q_1=i, O_1 | \lambda) = P(q_1=i | \lambda) P(O_1 | q_1=i, \lambda)$

$$\Rightarrow \delta_1(i) = \pi_i P(O_1 | q_1=i, \lambda)$$

Για  $t > 1$ , έχουμε ότι  $\delta_t(i) = \max_{q_1, \dots, q_{t-1}} P(q_1, q_2, \dots, q_t=i, O_1, O_2, \dots, O_t | \lambda) =$

$$= \max_{q_1, \dots, q_{t-2}, j} P(q_1, q_2, \dots, q_{t-1}=j, O_1, O_2, \dots, O_{t-1} | \lambda) P(q_t=i, O_t | \lambda, q_1, q_2, \dots, q_{t-1}=j, O_1, \dots, O_{t-1})$$

$$= \max_{q_1, \dots, q_{t-2}, j} P(q_1, q_2, \dots, q_{t-1}=j, O_1, O_2, \dots, O_{t-1} | \lambda) P(q_t=i, O_t | q_{t-1}=j, \lambda)$$

$$= \max_{q_1, \dots, q_{t-2}, j} P(q_1, q_2, \dots, q_{t-1}=j, O_1, O_2, \dots, O_{t-1} | \lambda) P(q_t=i | q_{t-1}=j, \lambda) P(O_t | q_t=i, q_{t-1}=j, \lambda)$$

$$= \max_{1 \leq j \leq 4} \delta_{t-1}(j) a_{ji} P(O_t | q_t=i, \lambda) \Rightarrow \delta_t(i) = P(O_t | q_t=i, \lambda) \max_{1 \leq j \leq 4} \delta_{t-1}(j) a_{ji}$$

Έχουμε λοιπόν ότι  $\delta_1(1) = 0.25 P(O_1=U | q_1=1) = 0.25 \cdot 0.4 = 0.1$

$$\delta_1(2) = 0.25 P(O_1=U | q_1=2) = 0.25 \cdot 0.3 = 0.075$$

$$\delta_1(3) = 0.25 P(O_1=U | q_1=3) = 0.25 \cdot 0.8 = 0.2$$

$$\delta_1(4) = 0.25 P(O_1=U | q_1=4) = 0.25 \cdot 0.75 = 0.1875$$

$$\delta_2(1) = P(O_2=V | q_2=1) \max \{ \delta_1(1) a_{11}, \delta_1(2) a_{21}, \delta_1(3) a_{31}, \delta_1(4) a_{41} \} =$$

$$= 0.6 \max \{ 0.1 \cdot 0.15, 0.075 \cdot 0.3, 0.2 \cdot 0.3, 0.1875 \cdot 0.25 \} =$$

$$= 0.6 \max \{ 0.015, 0.0225, 0.06, 0.046875 \} = 0.6 \cdot 0.06 = 0.036$$

Θεωρούμε επίσης την συνάρτηση  $\psi_t(i) = \arg\max_{1 \leq j \leq 4} \delta_{t-1}(j) a_{ji}$ ,  $t > 1$  ώστε να κρατάμε

την βέλτιστη κατάσταση  $j$  που μας οδήγησε στην κατάσταση  $i$ . Έχουμε  $\psi_2(1) = 3$ .

$$\begin{aligned} \delta_2(2) &= P(O_2 = V | q_2 = 2) \max \{ \delta_1(1) a_{12}, \delta_1(2) a_{22}, \delta_1(3) a_{32}, \delta_1(4) a_{42} \} = \\ &= 0.7 \max \{ 0.1 \cdot 0.3, 0.075 \cdot 0.15, 0.2 \cdot 0.25, 0.1875 \cdot 0.3 \} = \\ &= 0.7 \max \{ 0.03, 0.01125, 0.05, 0.05625 \} = 0.7 \cdot 0.05625 = 0.039375, \psi_2(2) = 4 \end{aligned}$$

Εργαζόμαστε κατ' αυτό τον τρόπο και προκύπτει τελικά ο ακόλουθος πίνακας:

		ΧΡΟΝΟΣ $t$									
$\delta_t(i)$		1	2	3	4	5	6	7	8	9	10
ΚΑΤΑΣΤΑΣΗ	1	0.1	0.036 <sup>(3)</sup>	0.0047 <sup>(2)</sup>	0.0017 <sup>(3)</sup>	0.00029 <sup>(2)</sup>	4.28e-5 <sup>(2)</sup>	1.54e-5 <sup>(3)</sup>	1.8e-6 <sup>(2)</sup>	6.6e-7 <sup>(3)</sup>	7.77e-8 <sup>(2)</sup>
	2	0.075	0.039 <sup>(4)</sup>	0.00324 <sup>(1)</sup>	0.0016 <sup>(3)</sup>	0.00035 <sup>(1)</sup>	2.67e-5 <sup>(1)</sup>	1.50e-5 <sup>(3)</sup>	1.38e-6 <sup>(1)</sup>	6.48e-7 <sup>(3)</sup>	5.99e-8 <sup>(1)</sup>
	3	0.2	0.009 <sup>(4)</sup>	0.00945 <sup>(2)</sup>	0.00036 <sup>(4)</sup>	0.00010 <sup>(1)</sup>	8.57e-5 <sup>(2)</sup>	3.34e-6 <sup>(4)</sup>	3.7e-6 <sup>(1)</sup>	1.44e-7 <sup>(4)</sup>	1.599e-7 <sup>(1)</sup>
	4	0.1875	0.015 <sup>(3)</sup>	0.00738 <sup>(2)</sup>	0.0007 <sup>(3)</sup>	0.00010 <sup>(1)</sup>	6.69e-5 <sup>(2)</sup>	6.42e-6 <sup>(3)</sup>	2.89e-6 <sup>(1)</sup>	2.77e-7 <sup>(3)</sup>	1.249e-7 <sup>(1)</sup>

όπου στις παρενθέσεις αναγράφεται η αντίστοιχη τιμή της συνάρτησης  $\psi$ .

2. Έχουμε  $q_{10}^* = \arg\max_{1 \leq j \leq 4} \delta_{10}(j) = 3$ ,  $q_9^* = \psi_{10}(q_{10}^*) = 1$ ,  $q_8^* = \psi_9(q_9^*) = 3$ ,  $q_7^* = \psi_8(q_8^*) = 1$

$q_6^* = \psi_7(q_7^*) = 3$ ,  $q_5^* = \psi_6(q_6^*) = 2$ ,  $q_4^* = \psi_5(q_5^*) = 1$ ,  $q_3^* = \psi_4(q_4^*) = 3$ ,  $q_2^* = \psi_3(q_3^*) = 2$

$q_1^* = \psi_2(q_2^*) = 4$ . Επομένως,  $Q^* = (4, 2, 3, 1, 2, 3, 1, 3, 1, 3)$

3.  $P^*(Q^*, O | \lambda) = \max_{1 \leq j \leq 4} \delta_{10}(j) \approx 1.599 \cdot 10^{-7} \Rightarrow P^*(Q^*, O | \lambda) \approx 1.599 \cdot 10^{-7}$

## Άσκηση 2.6

α. Έχουμε ότι  $\frac{\partial y}{\partial x} = \frac{\partial \sigma(Wx)}{\partial (Wx)} \frac{\partial (Wx)}{\partial x} = \frac{\partial \sigma(u)}{\partial u} W$  όπου  $u = Wx \in \mathbb{R}^n$

Επίσης  $\frac{\partial \sigma(u)}{\partial u} = \begin{bmatrix} \frac{\partial \sigma(u_1)}{\partial u_1} & \frac{\partial \sigma(u_1)}{\partial u_2} & \dots & \frac{\partial \sigma(u_1)}{\partial u_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \sigma(u_n)}{\partial u_1} & \frac{\partial \sigma(u_n)}{\partial u_2} & \dots & \frac{\partial \sigma(u_n)}{\partial u_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial \sigma(u_1)}{\partial u_1} & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{\partial \sigma(u_n)}{\partial u_n} \end{bmatrix} = \begin{bmatrix} \sigma'(u_1) & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma'(u_n) \end{bmatrix}$

Επομένως,  $\frac{\partial \sigma(u)}{\partial u} = \text{diag}(\sigma'(u))$  και  $\frac{\partial y}{\partial x} = \text{diag}(\sigma'(Wx)) W$

β. Δίνεται ότι  $L = \sum_{t=0}^T L_t$ . Κάθε επιμέρους χρονικό σφάλμα  $L_t$  εξαρτάται από την κατά-

σταση  $h_t$ , επομένως  $\frac{\partial L_t}{\partial W} = \frac{\partial L_t}{\partial h_t} \frac{\partial h_t}{\partial W}$ . Κάθε κατάσταση  $h_t$  εξαρτάται από τις

προηγούμενες, και έτσι  $\frac{\partial h_t}{\partial W} = \sum_{k=0}^t \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W} = \frac{\partial h_t}{\partial h_0} \frac{\partial h_0}{\partial W} + \sum_{k=1}^t \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$ . Έχουμε λοιπόν

ότι  $\frac{\partial L_t}{\partial W} = \frac{\partial L_t}{\partial h_t} \sum_{k=1}^t \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W} = \sum_{k=1}^t \frac{\partial L_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$ . Επομένως, προκύπτει ότι

$$\frac{\partial L}{\partial W} = \sum_{t=0}^T \frac{\partial L_t}{\partial W} \Rightarrow \frac{\partial L}{\partial W} = \sum_{t=0}^T \sum_{k=1}^t \frac{\partial L_t}{\partial h_t} \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W}$$

γ. Για  $T=3$ , έχουμε ότι  $\frac{\partial L}{\partial W} = \sum_{t=0}^3 \frac{\partial L_t}{\partial h_t} \sum_{k=1}^t \frac{\partial h_t}{\partial h_k} \frac{\partial h_k}{\partial W} = \frac{\partial L_1}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial L_2}{\partial h_2} \left( \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial h_2}{\partial W} \right) +$

$$+ \frac{\partial L_3}{\partial h_3} \left( \frac{\partial h_3}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial W} + \frac{\partial h_3}{\partial W} \right) = \frac{\partial L_1}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial L_2}{\partial h_2} \left( \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} \right) +$$

$$+ \frac{\partial L_3}{\partial h_3} \left( \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} + \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} \right) = \frac{\partial L_1}{\partial h_1} \frac{\partial h_1}{\partial W} + 2 \frac{\partial L_2}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W} + 3 \frac{\partial L_3}{\partial h_3} \frac{\partial h_3}{\partial h_2} \frac{\partial h_2}{\partial h_1} \frac{\partial h_1}{\partial W}$$

Κατά την εκτέλεση backpropagation σε  $n+1$  το πλήθος χρονικές στιγμές, χρειάζεται ο

υπολογισμός του γινομένου  $\frac{\partial h_{n+1}}{\partial h_n} \cdot \frac{\partial h_{n-1}}{\partial h_{n-2}} \dots \frac{\partial h_2}{\partial h_1}$  προκειμένου να βρεθεί το  $\frac{\partial h_n}{\partial W}$

Έχουμε ότι  $\frac{\partial h_i}{\partial h_{i-1}} = \frac{\partial \sigma(W h_{i-1} + U x_t)}{\partial h_{i-1}} = \text{diag } \sigma'(W h_{i-1} + U x_t) W$  Επομένως

χρειάζεται να πολλασιάσουμε τον  $\text{diag } \sigma'(W h_{i-1} + U x_t) W$  με τον εαυτό του

$n$  φορές.

δ. Έχουμε ότι  $M = Q \Lambda Q^{-1}$ . Τότε  $\prod_{i=1}^n M = \underbrace{(Q \Lambda Q^{-1})(Q \Lambda Q^{-1}) \dots (Q \Lambda Q^{-1})}_{n \text{ φορές}} =$

$$= Q \Lambda^n Q^{-1} \Rightarrow M^n = Q \Lambda^n Q^{-1}$$

$$\epsilon. \text{ Είναι } W^{30} = Q \Lambda^{30} Q^{-1} = \begin{pmatrix} -0.8 & 0.6 \\ 0.6 & 0.8 \end{pmatrix} \begin{pmatrix} 0.3^{30} & 0 \\ 0 & 0.55^{30} \end{pmatrix} \begin{pmatrix} -0.8 & 0.6 \\ 0.6 & 0.8 \end{pmatrix}$$

$$\text{Τελικά, } W^{30} \approx \begin{pmatrix} 5.85 \cdot 10^{-9} & 7.8 \cdot 10^{-9} \\ 7.8 \cdot 10^{-9} & 1.04 \cdot 10^{-8} \end{pmatrix}. \text{ Βλέπουμε ότι οι τιμές του } W$$

είναι πολύ κοντά στο μηδέν όταν οι ιδιοτιμές έχουν μέτρο μικρότερο της μονάδας.

Αυτό μπορεί να δημιουργήσει vanishing gradients, καθώς τα gradients που θα

πολ/στουν με  $W^{30}$  θα είναι πολύ κοντά στο μηδέν. Στην γενική περίπτωση έχουμε

τις εξής περιπτώσεις:

i. Εάν  $|\lambda_i| < 1$  τότε  $\lim_{n \rightarrow \infty} |\lambda_i|^n = 0$ . Τα στοιχεία του  $W^n$  τείνουν στο μηδέν

και υπάρχει το πρόβλημα των vanishing gradients.

ii. Εάν  $|\lambda_i| > 1$  τότε  $\lim_{n \rightarrow \infty} |\lambda_i|^n = \infty$ . Τα στοιχεία του  $W^n$  τείνουν στο άπειρο

και υπάρχει το πρόβλημα των exploding gradients.

iii. Εάν  $|\lambda_i| = 1$  τότε  $\lim_{n \rightarrow \infty} |\lambda_i|^n = 1$ . Τα στοιχεία του  $W^n$  δεν παρουσιάζουν μεταβολή

στο μέγεθος τους.

στ. Η πύλη  $f_t$  (forget gate) αφορά στο κατά πόσο θα "λησμονηθεί" η προηγούμενη κατάσταση του cell state. Αν έχει τιμές κοντά στο μηδέν, δεν διατηρείται η

προηγούμενη κατάσταση του cell state. Η πύλη  $i_t$  (input gate) καθορίζει πόσο θα

ληφθεί υπόψη το υποψήφιο cell state  $\tilde{C}_t$  κατά την ανανέωση του cell state. Η πύλη

$o_t$  (output gate) καθορίζει την επιρροή του cell state στην κρυφή κατάσταση.

ζ. Οι πύλες  $f_t$ ,  $i_t$ ,  $o_t$  έχουν μη αρνητικές τιμές στο διάστημα  $[0, 1]$  λόγω του

ορισμού τους με σιγμοειδή συνάρτηση.

η. Ναι, καθώς το  $C_t$  εξαρτάται από τα  $f_t, i_t, \tilde{C}_t$  που με την σειρά τους

εξαρτώνται από το προηγούμενο cell state.

θ. Έχουμε ότι  $C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$ . Για  $f_t = 1$  και  $i_t = 0$ , προκύπτει ότι

$$C_t = 1 \odot C_{t-1} + 0 \odot \tilde{C}_t \Rightarrow C_t = C_{t-1}. \text{ Επομένως, } \frac{\partial C_t}{\partial C_k} = \prod_{i=k+1}^t \frac{\partial C_i}{\partial C_{i-1}} = \prod_{i=k+1}^t 1 = 1 \Rightarrow$$

$$\frac{\partial C_t}{\partial C_k} = 1.$$

$$1. \text{ Έχουμε ότι } \frac{\partial C_t}{\partial C_{t-1}} = \frac{\partial (f_t \odot C_{t-1} + i_t \odot \tilde{C}_t)}{\partial C_{t-1}} = \frac{\partial (f_t \odot C_{t-1})}{\partial C_{t-1}} + \frac{\partial (i_t \odot \tilde{C}_t)}{\partial C_{t-1}} =$$

$$= \frac{\partial f_t}{\partial C_{t-1}} \odot C_{t-1} + f_t \odot \frac{\partial C_{t-1}}{\partial C_{t-1}} + \frac{\partial i_t}{\partial C_{t-1}} \odot \tilde{C}_t + i_t \odot \frac{\partial \tilde{C}_t}{\partial C_{t-1}} =$$

$$= \frac{\partial f_t}{\partial C_{t-1}} \odot C_{t-1} + f_t + \frac{\partial i_t}{\partial C_{t-1}} \odot \tilde{C}_t + i_t \odot \frac{\partial \tilde{C}_t}{\partial C_{t-1}} \quad \text{Υπολογίζουμε ξεχωριστά τις}$$

επιμέρους παραγώγους.

$$\frac{\partial f_t}{\partial C_{t-1}} = \frac{\partial \sigma(W_f h_{t-1} + U_f x_t)}{\partial C_{t-1}} = \frac{\partial \sigma(W_f h_{t-1} + U_f x_t)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial C_{t-1}} = \sigma'(W_f h_{t-1} + U_f x_t) \cdot$$

$$W_f \frac{\partial h_{t-1}}{\partial C_{t-1}}. \text{ Επίσης, } \frac{\partial h_{t-1}}{\partial C_{t-1}} = \frac{\partial (o_{t-1} \odot \tanh(C_{t-1}))}{\partial C_{t-1}} = \frac{\cancel{\partial o_{t-1}}}{\partial C_{t-1}} \odot \tanh(C_{t-1}) +$$



$$+ o_{t-1} \odot \frac{\partial \tanh(C_{t-1})}{\partial C_{t-1}} = o_{t-1} \odot \tanh'(C_{t-1}) \Rightarrow \frac{\partial h_{t-1}}{\partial C_{t-1}} = o_{t-1} \odot \tanh'(C_{t-1}).$$

$$\text{Συνεπώς, } \frac{\partial f_t}{\partial C_{t-1}} = \sigma'(W_f h_{t-1} + U_f x_t) W_f \underbrace{(o_{t-1} \odot \tanh'(C_{t-1}))}_{\delta} = \sigma'(W_f h_{t-1} + U_f x_t) W_f \delta$$

$$\text{Ακόμα, } \frac{\partial i_t}{\partial C_{t-1}} = \frac{\partial \sigma(W_i h_{t-1} + U_i x_t)}{\partial C_{t-1}} = \frac{\partial \sigma(W_i h_{t-1} + U_i x_t)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial C_{t-1}} = \sigma'(W_i h_{t-1} + U_i x_t) W_i \delta$$

$$\Rightarrow \frac{\partial i_t}{\partial C_{t-1}} = \sigma'(W_i h_{t-1} + U_i x_t) W_i \delta. \text{ Επίσης, } \frac{\partial \tilde{C}_t}{\partial C_{t-1}} = \frac{\partial \tanh(W_c h_{t-1} + U_c x_t)}{\partial C_{t-1}} =$$

$$= \frac{\partial \tanh(W_c h_{t-1} + U_c x_t)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial C_{t-1}} = \tanh'(W_c h_{t-1} + U_c x_t) W_c \delta \Rightarrow$$

$$\frac{\partial i_t}{\partial C_{t-1}} = \tanh'(W_c h_{t-1} + U_c x_t) W_c \delta. \text{ Συνολικά, έχουμε ότι } \frac{\partial C_t}{\partial C_{t-1}} = \frac{\partial f_t}{\partial C_{t-1}} \odot C_{t-1} +$$

$$+ f_t + \frac{\partial i_t}{\partial C_{t-1}} \odot \tilde{C}_t + i_t \odot \frac{\partial \tilde{C}_t}{\partial C_{t-1}} = \sigma'(W_f h_{t-1} + U_f x_t) W_f (\delta \odot C_{t-1}) + f_t +$$

$$+ \sigma'(W_i h_{t-1} + U_i x_t) W_i (\delta \odot \tilde{C}_t) + i_t \odot \tanh'(W_c h_{t-1} + U_c x_t) W_c \delta \Rightarrow$$

$$\frac{\partial C_t}{\partial C_{t-1}} = \sigma'(W_f h_{t-1} + U_f x_t) W_f \delta \odot C_{t-1} + f_t + \sigma'(W_i h_{t-1} + U_i x_t) W_i \delta \odot \tilde{C}_t +$$

$$i_t \odot \tanh'(W_c h_{t-1} + U_c x_t) W_c \delta$$

Είναι καλύτερο να χρησιμοποιείται το cell state λόγω της μορφής της  $\frac{\partial C_t}{\partial C_{t-1}}$ , που

δεν ευνοεί την εμφάνιση vanishing gradients σε αντίθεση με το hidden state των RNNs.