

Στοχαστικές Διαδικασίες και Βελτιστοποίηση στη Μηχανική Μάθηση

- ΘΕΜΑ 1^ο** :
1. Supervised Learning : b, d, f, i
 2. Unsupervised Learning : b, c, e
 3. Reinforcement Learning : α, h, g

ΘΕΜΑ 2^ο (α) Διαφορά Value-Policy Iteration :

Ο αλγόριθμος Policy iteration ξεκινάει από μια πολιτική, υπολογίζει την value function, όπου πορεία βρίσκει μια άλλη καλύτερη (ή ίδια) πολιτική. Δηλ. την αναβαθμίζει σε σε κάθε επανάληψη μέχρι να βρεθεί η βέλτιστη πολιτική.

Αντίστοιχα, ο Value Iteration ξεκινάει από μια Value function, και την βελτιώνει συνεχώς επαναληπτικά, μέχρι να φτάσει στην βέλτιστη. Στο τέλος εξάγει την βέλτιστη πολιτική.

(β) Διαφορά Value/Policy Iteration με Q-learning :

Ο αλγόριθμος Q-learning δεν θεωρεί γνωστές τις πιθανότητες μεταβάσεων αλλά και τις rewards, μεταξύ των μεταβάσεων.

$$(γ) V_{old}(K) = 1.4, V_{old}(\Pi) = 0.5, V_{old}(A) = 1, V_{old}(\Delta) = 1.1$$

$$V_{new}(s) = \max_{\alpha} \begin{cases} \uparrow 0.7(-4 + 0.9 \cdot 0.5) + 0.15(1 + 0.9 \cdot 1) + 0.15(2 + 0.9 \cdot 1.1) \\ \downarrow 0.7(+10 + 0.9 \cdot 1.4) + 0.15(1 + 0.9 \cdot 1) + 0.15(2 + 0.9 \cdot 1.1) \\ \rightarrow 0.7(+2 + 0.9 \cdot 1.1) + 0.15(10 + 0.9 \cdot 1.4) + 0.15(-4 + 0.9 \cdot 0.5) \\ \leftarrow 0.7 \cdot (1 + 0.9 \cdot 1) + 0.15(+10 \cdot 0.9 \cdot 1.4) + 0.15(-4 + 0.9 \cdot 0.5) \end{cases}$$

$$V_{new}(s) = \max_{\alpha} (-1.75, 8.61, 3.24, 2.48)$$

απλ : $V_{new}(s) = 8.61$

ΘΕΜΑ 3^ο

(α) Ο αλγόριθμος Hill Climbing είναι ευρισκτικός αναζήτησης. Πάντοτε διαλέγει καταστάσεις οι οποίες βελτιώνουν την ευαρμογή που μελετάει, δηλ. οδηγεί σε ακρότατο, αβυσσώσας τις υπόλοιπες καταστάσεις. Εξ'αίτιας αυτού όμως παγιδεύεται σε τοπικά ακρότατα - μη βέλτεστες λύσεις.

Ο simulated annealing στο ίδιο πρόβλημα, δεν απορρίπτει πάντοτε μια «χειρότερη» κατάσταση, αλλά κάποιες φορές την αποδέχεται, με μια πιθανότητα η οποία όσο προχωράει ο αλγόριθμος όσο και μικραίνει. Έτσι, κάνοντας λάθος κάποιες φορές, απεγκλωβίζεται από τοπικά ακρότατα.

(β) Όταν η proposed ενέργεια $>$ ενέργεια συστήματος, ο έλεγχος για το αν θα πραγματοποιηθεί το βήμα δίνεται με τη σχέση:
$$\text{prob} = \exp\left(-\frac{E_{\text{prop}} - E_c}{T_c}\right)$$

Επομένως όσο η $T_c \uparrow$ αυξάνει η πιθανότητα αποδοχής κάποιου χειρότερου βήματος. Επί καθώς $T_c \downarrow$ επιλέγονται οι καλύτερες κινήσεις.

(γ) $E_1 = 37$ $E_2 = 65$, $T_c = 16$

αφού $E_2 > E_1$:
$$\text{prob} = \exp\left(-\frac{65 - 37}{16}\right) = 0.1738$$

αν $a \in [0, 0.1738]$ το βήμα θα πραγματοποιηθεί.

(α)
ΘΕΜΑ 4^ο : Ο Naïve Bayes κάνει την παραδοχή πως υπάρχει ανεξαρτησία μεταξύ των features.

Πλεονεκτήματα :

- Απλός, εύκολος στην υλοποίηση.
- Δεν χρειάζεται πολλά Training data.
- Χρειάζεται διακριτά και συνεχή δεδομένα
- Γραμμικό scalability με 2α features.
- Αν και στην πραγματικότητα είναι βέβαια βέβαιη η ανεξαρτησία δίνει καλά αποτελέσματα.
- Είναι σπρίντ
- χρησιμοποιείται και σε Binary και σε multiclass classification.

(β) Συμβολίζω: εμφάνισαν πονοκέφαλο με "+"
Δεν - - - - με - - - -

$$\psi_{\text{axw}}: P(+|r, Y, \geq 50), P(-|r, Y, \geq 50)$$

$$\rightarrow P(+|\Gamma, Y, \geq 50) = P(+). P(\Gamma|+). P(Y|+). P(\geq 50|+)$$

$$\rightarrow P(-|r, y, \geq 50) = P(-) \cdot P(r|-) \cdot P(y|-) \cdot P(\geq 50|-)$$

PROBS : $P(+)=\frac{2990}{5000}=0.598$, $P(-)=\frac{2010}{5000}=0.402$

$$P(r|+) = \frac{1270}{2990} = 0.425 \quad , \quad P(r|-) = \frac{730}{2010} = 0.363$$


$$P(Y|+) = \frac{1090}{2990} = 0.365, \quad P(Y|-) = \frac{1190}{2010} = 0.592$$

$$P(\geq 50 | +) = \frac{1790}{2990} = 0.599, \quad P(\geq 50 | -) = \frac{1410}{2010} = 0.701$$

Jawab: $P(+|r, y, z, 50) = 0.598 \cdot 0.425 \cdot 0.365 \cdot 0.599 = \underline{0.055566}$

$$p(-10, Y, \geq 50) = 0.402 \cdot 0.363 \cdot 0.592 \cdot 0.701 = \underline{0.0609}$$

Άρα η συνάρτηση ΔΕΝ εμφάνισε ποσοτέκλιο.



$$6 \text{ in}_i = 1 - \left(\frac{1270}{1270+730} \right)^2 - \left(\frac{730}{2000} \right)^4$$


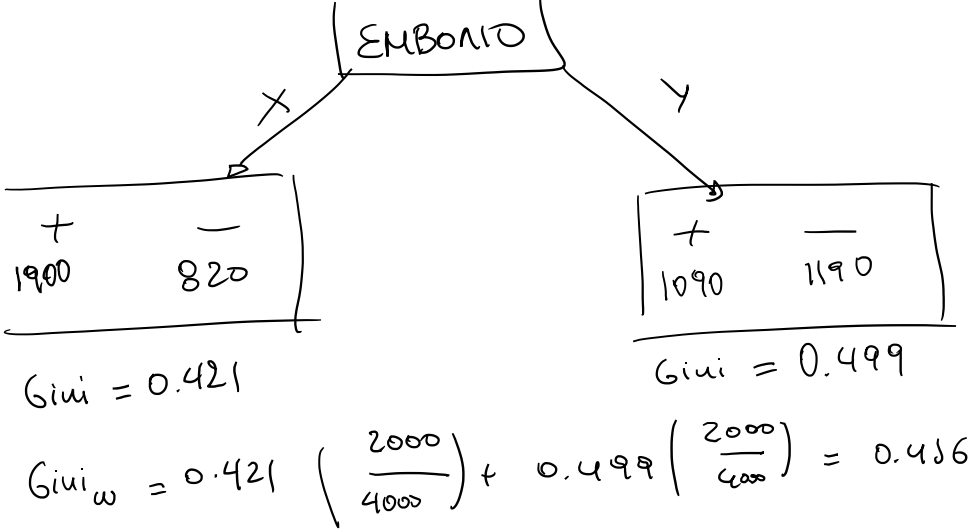
$$b_{iui} = 0.46355$$

$$G_{ini} = 1 - \left(\frac{1720}{1720+1280} \right)^2 - \left(\frac{1280}{3000} \right)^2$$

$$Gini = 0.4892444$$

$$\text{Gini weights} = 0.46355 \left(\frac{2000}{5000} \right) + 0.4892449 \left(\frac{3000}{5000} \right)$$

⇒ Given weighted = 0.478



Άρα το ΕΡΩΔΙΟ δίνει οτι ειδη παρι
 έχει καλύτερο Gini.

ΘΕΜΑ 5^ο

(α) Διαφορές μηχανής Boltzmann (BM) με
 Restricted Boltzmann Machine (RBM).

Σε ένα δίκτυο με BM, οι Visible με τους
 hidden νευρώνες συνδέονται όλοι μεταξύ τους,
 ακόμα και αν βρίσκονται στο ίδιο layer.

Στα RBMs νευρώνες του ίδιου layer δεν
 συνδέονται, εμφανίζουν δηλ. ένα διμερή γράφο.
 Η αντανόηση αυτή στα RBMs τα κάνει καταλληλότερα
 για Training καθώς είναι πιο φτηνά υπολογιστικά.

Εφαρμογές RBM:

- Dimensionality Reduction
- Feature Extraction
- Classification
- Stacking of RBMs → Deep belief Networks
- Topic Modelling

(β) Ο αλγόριθμος Metropolis Hastings λαμβάνει αποφάσεις (αποδοχή-απόρριψη) με βάση την πιθανότητα της παρατηρηθείσας έκδοσης του εγχειρίδιου να είναι αποδεκτή. Αυτό δεν απαιτεί γνώση της Normalizing Constant (NC). Συγκεκριμένα αν $\pi(x)$ που έχω ως $p(x) = NC \cdot \pi(x)$ η ακριβής παρανομή:

$$\frac{p(x_{new})}{p(x_{old})} = \frac{NC \cdot \pi(x_{new})}{NC \cdot \pi(x_{old})} = \frac{\pi(x_{new})}{\pi(x_{old})}$$


όπου δεν απαιτείται η γνώση της.

Το δείγμα των παρατηρήσεων που δημιουργούνται από τον αλγόριθμο είναι συσχετισμένο (autocorrelated).

ΘΕΜΑ 6^ο:

Σειρά: A, D, E, C, B

Εναλλακτικές:



A , D , E , C , B


#0 : 0 ∞ ∞ ∞ ∞

#1 : 0 8(A) 15(A) ∞ 7(A)

#2 : 0 8(A) 11(D) 10(B) 7(A)


#3 : 0 8(A) 11(D) 10(B) 7(A)

Οι τελικές αποδόσεις φαίνονται στο σχήμα:



ΘΕΜΑ 7ο

$$P = \begin{bmatrix} 0.2 & 0.3 & 0.5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.4 & 0.6 & 0 \\ 0.3 & 0 & 0.5 & 0.2 & 0 & 0 \\ 0 & 0.3 & 0 & 0 & 0 & 0.7 \\ 0 & 0 & 0 & 0 & 0.4 & 0.6 \\ 0 & 0 & 0 & 0 & 0.7 & 0.3 \end{bmatrix}$$



$\{A, C\}$: ανοικτή

$\{D, B\}$: ανοικτή

$\{F, E\}$: κλειστή
επαναληπτική

Εστιάζουμε στην κλειστή κλάση: $P = \begin{bmatrix} 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}$

$$\pi = \pi \cdot P$$

$$(\pi_1, \pi_2) = (\pi_1, \pi_2) \begin{pmatrix} 0.4 & 0.6 \\ 0.7 & 0.3 \end{pmatrix} \begin{cases} \pi_1 = 0.4\pi_1 + 0.7\pi_2 \\ \pi_2 = 0.6\pi_1 + 0.3\pi_2 \\ \pi_1 + \pi_2 = 1 \end{cases} \rightarrow$$

$$\pi_1 + \pi_2 = 1$$

$$\Rightarrow \pi_1 = 0.4\pi_1 + (1 - \pi_1) \cdot 0.7 = 0.6\pi_1 = 0.7 - 0.7\pi_1 \Rightarrow 1.3\pi_1 = 0.7$$

$$\Rightarrow \boxed{\pi_1 = \frac{7}{13}} \quad \text{και} \quad \pi_2 = 1 - \pi_1 \Rightarrow \boxed{\pi_2 = \frac{6}{13}}$$

όρα η αναλλοίωτη κατανομή είναι

$$(\pi_A, \pi_B, \pi_C, \pi_D, \pi_E, \pi_F) = \left(0, 0, 0, 0, \frac{7}{13}, \frac{6}{13}\right)$$

Νικόλαος
Μανιάτης